

文献引用格式: 侯杰, 倪建成. 基于 GoogLeNet 的手写体汉字识别 [J]. 通信技术, 2020, 53(05): 1127-1132.

HOU Jie, NI Jian-cheng. Handwritten Chinese Characters Recognition based on GoogLeNet [J].  
Communications Technology, 2020, 53(05): 1127-1132.

doi:10.3969/j.issn.1002-0802.2020.05.012

## 基于 GoogLeNet 的手写体汉字识别<sup>\*</sup>

侯 杰, 倪建成

(曲阜师范大学 软件学院, 山东 曲阜 273165)

**摘 要:** 近年来基于深度学习的方法识别手写体汉字取得了很多突破, 但现有的一些方法存在计算参数多、模型收敛慢、训练时间长的缺点。针对以上问题, 提出了基于 GoogLeNet 的脱机手写体汉字识别模型 HCCR-IncBN, 模型使用了 5 个 Inception-v2 模块, 训练参数较少, 模型收敛更快, 存储整个模型只需要 26MB 的存储空间。实验利用 HCCR-IncBN 模型在 ICDAR2013 数据集获得了 95.94% 的识别准确率, 表明模型在没有使用任何手写体汉字的特定领域知识和无需人工提取其他特征的前提下能够获得较高的识别效果。

**关键词:** 手写体汉字识别; 卷积神经网络; Inception 模块; Batch Normalization 算法

**中图分类号:** TP391; TP183      **文献标志码:** A      **文章编号:** 1002-0802(2020)-05-1127-06

## Handwritten Chinese Characters Recognition based on GoogLeNet

HOU Jie, NI Jian-cheng

(College of Software, Qufu Normal University, Qufu Shandong 273165, China)

**Abstract:** In recent years, the handwritten Chinese characters recognition based on deep learning methods has made many breakthroughs, but some existing methods have the disadvantages of multiple calculation parameters, slow model convergence and long training time. To solve these above problems, an offline handwritten Chinese character recognition model HCCR-IncBN based on GoogLeNet is proposed. The model uses 5 Inception-v2 modules with fewer training parameters and faster model convergence, and only 26MB is needed to store the whole model. In the experiment, the HCCR-IncBN model is used to identify ICDAR2013 dataset, and the accuracy of 95.94% is acquired. This indicates that this model can achieve a fairly high recognition effect without using any domain-specific knowledge of handwritten Chinese characters and with no need to extract other features manually.

**Key words:** handwritten Chinese character recognition; convolutional neural network; inception module; Batch Normalization Algorithm

### 0 引 言

脱机手写体汉字识别已有近 50 年的研究历史, 因为汉字类别数较大 (参照 GB2312-80 标准, 常用汉字有 6763 个类别)、易混淆的相似字形多以

及书写风格的多样性使其一直是模式识别领域的研究难点。传统的手写体汉字识别分为三个步骤: 图像预处理、特征提取与分类。预处理一般通过模糊化、灰度化、二值化以及归一化等方法来实现, 目

<sup>\*</sup> 收稿日期: 2020-01-16; 修回日期: 2020-04-15      Received date: 2020-01-16; Revised date: 2020-04-15  
通讯联系人: nijch@163.com      Corresponding author: nijch@163.com

的是加强图像的有用特征、去除其他无关的噪声,从而使得特征提取更加方便<sup>[1]</sup>。特征提取是从原始输入中提取能表达特定汉字本身而又区别于其他汉字的无冗余性低维图像特征,目前效果较好的是一些统计特征,如 Gabor 特征、Gradient 特征、HOG 特征<sup>[2-3]</sup>。传统方法中常用的分类器有 SVM<sup>[4]</sup>、线性判别分析(LDA)<sup>[5]</sup>和修正二次判别函数(MQDF)<sup>[6]</sup>。近年来基于修正二次判别函数的方法依然是研究热点,然而作为效果最优的传统识别方法,修正二次判别函数在典型手写体汉字数据集 CASIA-HWDB 和 ICDAR2013 上的识别准确率都还没有达到 93%<sup>[6-8]</sup>。

随着计算资源性能的提高和大量标注数据集的出现,基于深度学习特别是卷积神经网络(CNN)的方法在计算机视觉和模式识别领域取得了巨大的成功<sup>[9-11]</sup>,对手写体汉字的识别也逐渐由传统方法转变为基于神经网络的方法。多列深度神经网络(MCDNN)<sup>[12]</sup>被认为是第一个将 CNN 成功应用到手写体汉字识别的模型,在 ICDAR2013 数据集上取得了 95.78% 的准确率,其使用不同的数据集训练了八个网络,每个网络都含有四个卷积层和两个全连接层。Wu 等人<sup>[13]</sup>采用基于 CNN 的模型在 ICDAR 数据集上实现了 94.77% 的准确率,获得了 2013 年 ICDAR 脱机手写体识别竞赛的第一名,第二年他们通过采用 4 种交替训练松弛卷积神经网络(ATR-CNN)的集成模式<sup>[14]</sup>来改进模型,达到了 96.06% 的准确率。2015 年 Zhong 等人将传统的 Gabor 特征提取与 CNN 结合提出了 HCCR-Gabor-GoogLeNet<sup>[15]</sup>,在 ICDAR2013 数据集上的识别准确率为 96.35%,是在该数据集上第一个超越人类表现的模型。2017 年 Zhang 等人<sup>[16]</sup>将传统的归一化 Gradient 特征映射与 CNN 结合,并采用一个适配层后在 ICDAR2013 数据集上取得了 97.37% 的准确率。

以上模型虽然取得了不错的识别效果,但大都存在调优参数多、网络收敛慢、存储模型空间大等问题。由此,本文设计了一个基于 GoogLeNet 的卷积神经网络 HCCR-IncBN,该模型利用了 Inception 模块稀疏连接的优点,对同一输入特征映射进行多个尺度上的卷积操作,并多次使用 1x1 卷积核来压缩数据,在增加网络深度的同时能够保证对计算资源的高效利用;为了加快模型收敛,在整个网络结构中充分应用了 BN 算法。在实验阶段,以数据集 CASIA-HWDB1.1 为训练集来识别 3755 个常用简体汉字,在 ICDAR2013 数据集上取得了 95.94% 的准

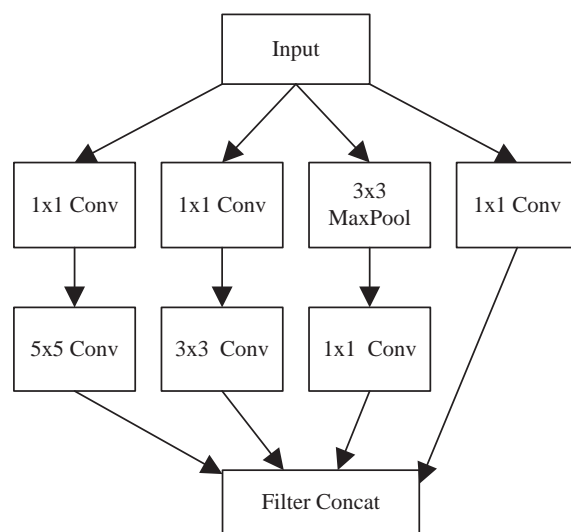
准确率;另外,以数据集 MNIST 作为实验数据,在测试集上取得了 99.37% 的识别准确率。

## 1 卷积神经网络模型

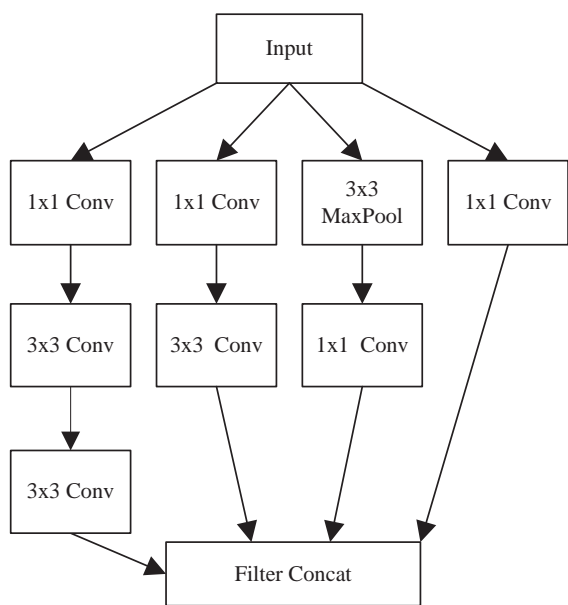
### 1.1 Inception 模块

提高深度神经网络表现的最直接方式就是增加网络的深度和宽度,经典的 AlexNet 和 VGG 网络正是以此设计网络结构达到了更好的效果,但这会使得计算参数过多,消耗大量计算资源甚至造成过拟合问题。文献[10]提出的 GoogLeNet 通过向网络中引入稀疏性可以在很大程度上解决上述问题,组成 GoogLeNet 的基本模块为 Inception,它把相关性强的特征先聚集到一起,每一种尺寸的卷积输出都作为总特征的一部分。

图 1(a)和图 1(b)分别展示了 Inception-v1 和 Inception-v2 的模块结构。Inception-v1 模块采用的卷积核大小分别为 1x1、3x3 和 5x5。与 Inception-v1 相比,Inception-v2 模块将 5x5 的卷积操作分成了两个 3x3 的卷积操作,使得计算效率进一步提升,本文采用的是 Inception-v2 模块。模块中 1x1 卷积操作的主要作用是压缩输入数据的通道数从而减少参数计算量,该操作可以使得卷积参数降低到原来的三分之一。为了保证 Inception 模块中三个尺寸的卷积操作和最大池化操作的输出可以进行维度上的连接,需要将卷积操作的步长设置为 1、Padding 方式设置为‘SAME’,将池化操作的步长也设置为 1。



(a) Inception-v1



(b) Inception-v2

图 1 Inception 模块结构图

## 1.2 HCCR-IncBN 模型结构

图 2 展示了 HCCR-IncBN 模型的结构以及每层输出特征映射的维度。该模型一共有 15 层（只计算卷积层和全连接层），包括 3 个卷积层、5 个 Inception 模块和 2 个全连接层。原始输入为  $64 \times 64$  大小的灰度图像。模型开始是两组“卷积 + 最大池化”操作，卷积核大小为  $3 \times 3$ ，步长为 1，最大

池化操作的池化窗口为  $2 \times 2$ ，步长为 2，整个模型中的四次卷积操作都采用此参数配置。第二个池化操作后是 5 个 Inception 模块，其中在 Inception2 和 Inception4 后设置了最大池化层，在最后一个 Inception 模块后设置了  $1 \times 1$  的卷积操作，该操作将  $4 \times 4 \times 608$  的特征映射压缩为  $4 \times 4 \times 256$ 。 $1 \times 1$  卷积操作完成后需要将特征映射扁平化为 4096 维的向量，之后开始全连接层的操作，第一个全连接层包含 1024 个神经元，输出层神经元的具体个数根据不同的数据集来设置（HWDB 数据集设置为 3755）。在 HCCR-IncBN 模型中，所有卷积层（包括 Inception 模块中的卷积层）和全连接层后面都连接了一个 BN 层，即在 ReLu 激活函数之前先执行 BN 算法。HCCR-IncBN 模型涉及的计算参数数量为 6849035，按照存储一个浮点数需要 4 个字节计算，存储模型所需的存储空间约为 26.12MB。表 1 列出了 5 个 Inception 模块中各卷积操作滤波器个数的具体设置。

表 1 Inception 模块各卷积操作的滤波器个数

|                                   | 1  | 2  | 3   | 4   | 5   |
|-----------------------------------|----|----|-----|-----|-----|
| the Conv1x1 before Double Conv3x3 | 64 | 64 | 96  | 96  | 128 |
| Double Conv3x3                    | 96 | 96 | 128 | 128 | 160 |
| the Conv1x1 before Conv3x3        | 64 | 64 | 64  | 96  | 128 |
| Conv3x3                           | 64 | 96 | 96  | 128 | 160 |
| the Conv1x1 after MaxPool3x3      | 32 | 64 | 128 | 128 | 128 |
| Conv1x1                           | 64 | 64 | 224 | 192 | 160 |




图 2 HCCR-IncBN 手写体汉字识别模型

## 1.3 批量标准化层

批量标准化 (Batch Normalization, BN)<sup>[17]</sup> 方法用来解决神经网络在训练过程中出现的内部协变量转移问题 (Internal Covariate Shift)，由于在训练神经网络的过程中前一层参数一直更新，导致后一层输入不断变化。如果神经网络在每次迭代中都要重新学习不同的数据分布，网络就会很难收敛，深层

网络的训练困难就在于此。针对此问题，在每一层的输出后面增加一个 BN 层，将网络下一层的输入都标准化为均值为 0、方差为 1 的分布，从而达到固定数据分布、降低内部协变量转移的目的。对于神经网络的某一层，假设输入为  $d$  维的数据： $x=(x^1, \dots, x^d)$ ，对每个维度进行归一化的公式为：

$$y^{(k)} = \gamma^{(k)} \hat{x}^{(k)} + \beta^{(k)} \quad (1)$$

式中  $y^{(k)}$  代表最终标准化后的数据, 参数  $\gamma^{(k)}$  和  $\beta^{(k)}$  分别代表缩放参数和偏移参数,  $\hat{x}^{(k)}$  是基于整个训练集的直接标准化结果, 其计算细节如下:

$$\hat{x}^{(k)} = \frac{x^{(k)} - E(x^{(k)})}{\sqrt{\text{Var}[x^{(k)}]}} \quad (2)$$

在实际训练过程中, 难以让每一个训练步骤都使用整个训练集, 在神经网络的训练中优化损失函数一般都采用最小批次梯度下降法, 对于 BN 算法, 只要每一个批次都取样于相同的分布, 那么也可以使用一个批次数据的均值和方差来完成 BN 标准化过程。考虑样本数为  $m$  的最小批次  $B: B=\{x_1, \dots, x_m\}$ , 整个 BN 算法过程描述如下。

#### 算法 1 BN 算法

输入: 最小批次的样本数据:  $B=\{x_1, \dots, x_m\}$  以及要被学习的参数  $\gamma, \beta$  输出:  $\{y_i = BN_{\gamma, \beta}(x_i)\}$

a) 计算输入数据的均值:  $\mu_B \leftarrow \frac{1}{m} \sum_{i=1}^m x_i$

b) 计算输入数据的方差:  $\delta_B^2 \leftarrow \frac{1}{m} \sum_{i=1}^m (x_i - \mu_B)^2$

c) 对该批次数据进行直接标准化操作:

$$\hat{x}_i \leftarrow \frac{x_i - \mu_B}{\sqrt{\delta_B^2 + \epsilon}}$$

d) 变换重构:  $y_i \leftarrow \gamma \hat{x}_i + \beta = BN_{\gamma, \beta}(x_i)$

## 2 实验结果与分析

### 2.1 实验参数设置


本文使用 TensorFlow 深度学习平台来实现 HCCR-IncBN 模型, 初始学习率设为 0.001, 按照指数衰减的方式更新学习率, 使用 Adam 梯度下降算法最小化损失函数, 最小批次设置为 128。为了避免过拟合, 在全连接层后面使用了 dropout 机制以及对权重参数添加了 L2 范数约束, dropout 数值设置为 0.6, 权重衰减率设置为  $10^{-4}$ , 另外也使用了‘早停’机制来控制训练过程。实验的硬件条件为 Intel (R) Xeon (R) Gold 6130、NVIDIA Tesla P100; 操作系统为 Ubuntu 16.04, 系统内存为 256G, 基础配置为 CUDA9.0, python3.7, TensorFlow1.14。

### 2.2 手写体汉字识别结果

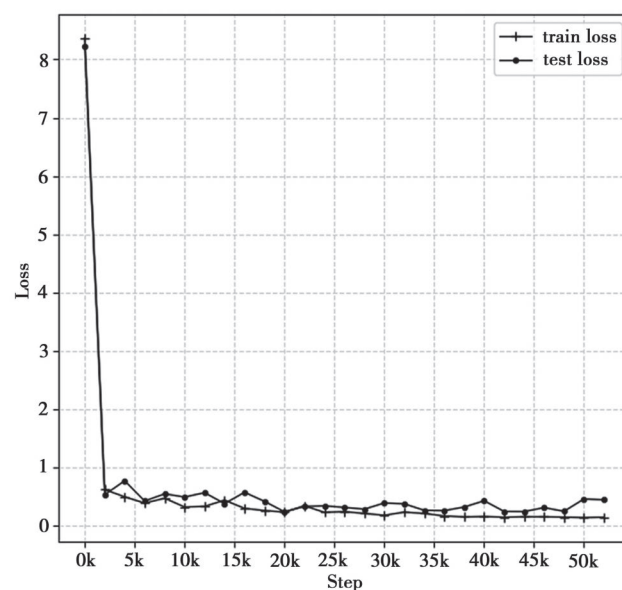
实验使用包含 3755 个类别的大规模数据集

CASIA-HWDB1.1 来训练模型, 该数据集由 300 人书写, 共有 1 121 749 个样本。测试数据为数据集 ICDAR2013, 由 60 人书写, 共有 224 419 个样本。输入图片大小为 64x64, 设置训练周期为 6 个 epoch (一个 epoch 含有 8 763 次迭代), 训练时间仅为 3 个小时。

图 3 (a) 和 (b) 显示了数据集 HWDB1.1 训练过程中准确率和损失函数的变化, 可以看出模型在训练迭代到 3000 次左右时损失函数就降到了 1.0 以下, 第 20 000 次迭代后测试准确率普遍保持在 95% 以上, 对数据集 ICDAR2013 的最终识别准确率如表 2 所示。



(a) 数据集 HWDB 训练过程准确率变化图



(b) 数据集 HWDB 训练过程损失函数变化图

图 3 数据集 HWDB1.1 训练过程中准确率和损失函数变化



表 2 ICDAR2013 数据集识别结果

| 训练集                         | 测试集                          | Top1    | Top3    | Top5    |
|-----------------------------|------------------------------|---------|---------|---------|
| HWDB1.1 ( 1121749 samples ) | ICDAR2013 ( 224419 samples ) | 95.94 % | 99.09 % | 99.46 % |

表 3 展示了基于 ICDAR2013 数据集的不同识别方法的比较。可以看出, 与表中的方法 1、2 相比, HCCR-IncBN 模型在识别准确率和模型参数的数量方面都具有较大的优势。方法 1 是 2013 年 ICDAR 手写体识别比赛的冠军, 其输入表示很小, 但是模型存储量高达 2460MB。随着算法的改进和网络的优化, 近几年一些成功的模型涉及的计算参数数量逐步降低。方法 2 是 ATR-CNN 的单一模型, 其输入是 1x48x48 的二值化图像, 但是模型存储量约是我们的两倍。方法 3 也是基于 GoogLeNet, 在识别准确率方面 HCCR-IncBN 比其低了 0.41%,

但是在模型存储方面我们更优一些, 具体来说, HCCR-Gabor-GoogLeNet 使用的是 Inception-v1 模块且提取了原图像的 Gabor 特征, 其输入表示大小为 9x120x120, 而 HCCR-IncBN 模型是基于 Inception-v2 模块, 输入表示大小为 1x64x64, 且训练集只使用了 HWDB1.1。方法 4 致力于设计一个紧凑型的 CNN 网络来提高手写体识别的效率, 在模型存储方面具有很大的优越性, 与之相比, HCCR-IncBN 模型的输入表示较小, 且方法 4 的模型在训练过程中要不断的进行卷积层的低秩分解和修剪权重的操作, 模型训练期间会耗费大量的时间和计算资源。

表 3 各手写体汉字识别方法的比较

|   | 模型                                   | 识别准确率  | 输入                | 输入大小      | 模型大小     | 训练数据集       |
|---|--------------------------------------|--------|-------------------|-----------|----------|-------------|
| 1 | CNN-Fujitsu <sup>[13]</sup>          | 94.77% | 灰度图像              | 1x48x48   | 2460 MB  | HWDB1.1     |
| 2 | ATR-CNN <sup>[14]</sup>              | 95.04% | 二值图像              | 1x48x48   | 51.64 MB | HWDB1.1     |
| 3 | HCCR-Gabor-GoogLeNet <sup>[15]</sup> | 96.35% | Gabor 特征映射 + 灰度图像 | 9x120x120 | 27.77 MB | HWDB1.0+1.1 |
| 4 | HCCR-CNN9Layer <sup>[18]</sup>       | 97.09% | 灰度图像              | 1x96x96   | 2.3 MB   | HWDB1.0+1.1 |
| 5 | HCCR-IncBN ( our )                   | 95.94% | 灰度图像              | 1x64x64   | 26.12 MB | HWDB1.1     |

### 2.3 MNIST 数据集实验结果

为进一步评估模型的识别能力, 使用 MNIST 数据集进行了手写体数字的识别实验。HCCR-IncBN 模型输入设置为 28x28, 由于 MNIST 数据集较小, 为增强泛化能力, 将 dropout 数值修改为 0.5。共训练了 14040 次, 在测试集上的识别准确率为 99.37%。表 4 展示了在 MNIST 数据集上不同识别方法的比较, 可以看出 HCCR-IncBN 模型具有最高的识别准确率。

表 4 不同识别模型的比较

| 模型                       | 识别准确率  |
|--------------------------|--------|
| CNN-SVM <sup>[19]</sup>  | 98.9%  |
| 改进 CNN <sup>[20]</sup>   | 99.22% |
| LeNet-DL <sup>[21]</sup> | 99.34% |
| HCCR-IncBN               | 99.37% |

## 3 结 语

本文设计了一个 15 层的深度卷积神经网络模型 HCCR-IncBN 用于汉字的手写体识别。该模型充分利用了 Inception 模块稀疏连接的优点, 保存整个模型仅需 26MB 的存储空间, 在获得较优识别准确率的同时能够较快的收敛 (使用 HWDB1.1 数据集训练模型仅需 3 个小时)。HCCR-IncBN 模型在

ICDAR2013 和 MNIST 数据集上分别取得了 95.94% 和 99.37% 的识别准确率, 优于当下大部分识别模型。在今后的工作中, 我们会尝试设计更紧凑的 CNN 模型来提高模型的识别效率, 另外, 将模型与手写体汉字的特定领域知识 (如字符形状归一化、传统 Gradient 特征与 Gabor 特征提取等) 相结合来进一步探索提高模型的识别准确率。

### 参考文献:

- [1] 孙华, 张航. 汉字识别方法综述[J]. 计算机工程, 2010, 36(20):194-197.  
SUN Hua, ZHANG Hang. A review of Chinese character recognition methods [J]. Computer Engineering, 2010, 36(20):194-197.
- [2] 金连文, 钟卓耀, 杨钊等. 深度学习在汉字识别中的应用综述[J]. 自动化学报, 2016, 42(8):1125-1141.  
JIN Lian-wen, ZHONG Zhuo-yao, Yang Zhao, et al. Applications of deep learning for handwritten Chinese character recognition: A Review [J]. Acta Automatica Sinica, 2016, 42(08): 1125-1141.
- [3] 金连文, 覃剑钊. 手写汉字识别弹性网格 Gabor 特征提取方法的研究[J]. 计算机应用研究, 2004(12): 163-165.  
JIN Lian-wen, TAN Jian-zhao. Study on Gabor filter-

- based handwritten Chinese character feature extraction[J]. Application Research of Computers, 2004(12):163–165.
- [4] Kaensar C. A comparative study on handwriting digit recognition classifier using neural network, support vector machine and k-nearest neighbor[C]//The 9th International Conference on Computing and Information Technology (IC2IT2013). Berlin: Springer, 2013: 155–163.
- [5] Gao Tianfu, Liu Chenglin. High accuracy handwritten Chinese character recognition using LDA-based compound distances[J]. Pattern Recognition, 2008, 41(11): 3442–3451.
- [6] Long Teng, Jin Lianwen. Building compact MQDF classifier for large character set recognition by subspace distribution sharing[J]. Pattern Recognition, 2008, 41(09): 2916–2925.
- [7] Liu Chenglin, Yin Fei, Wang Dahan, et al. Online and offline handwritten Chinese character recognition: benchmarking on new databases[J]. Pattern Recognition, 2013, 46(01): 155–162.
- [8] Zhou Mingke, Zhang Xuyao, Yin Fei, et al. Discriminative quadratic feature learning for handwritten Chinese character recognition[J]. Pattern Recognition, 2016, 49: 7–18.
- [9] Krizhevsky A, Sutskever I, Hinton G E. Imagenet classification with deep convolutional neural networks[C]//Advances in neural information processing systems. Cambridge, MA: MIT Press, 2012: 1097–1105.
- [10] Szegedy C, Liu Wei, Jia Yangqing, et al. Going deeper with convolutions[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. Washington DC: IEEE Computer Society, 2015: 1–9.
- [11] Sabour S, Frosst N, Hinton G E. Dynamic routing between capsules[C]//Advances in neural information processing systems. Cambridge, MA: MIT Press, 2017: 3856–3866.
- [12] Cireşan D, Meier U. Multi-column deep neural networks for offline handwritten Chinese character classification[C]//2015 international joint conference on neural networks (IJCNN). Piscataway, NJ: IEEE Press, 2015: 1–6.
- [13] Yin Fei, Wang Qiufeng, Zhang Xuyao, et al. ICDAR 2013 Chinese handwriting recognition competition[C]//2013 12th International Conference on Document Analysis and Recognition. Piscataway, NJ: IEEE Press, 2013: 1464–1470.
- [14] Wu Chunpeng, Fan Wei, He Yuan, et al. Handwritten character recognition by alternately trained relaxation convolutional neural network[C]//2014 14th International Conference on Frontiers in Handwriting Recognition. Piscataway, NJ: IEEE Press, 2014: 291–296.
- [15] Zhong Zhuoyao, Jin Lianwen, Xie Zecheng. High performance offline handwritten Chinese character recognition using googlenet and directional feature maps[C]//2015 13th International Conference on Document Analysis and Recognition (ICDAR). Piscataway, NJ: IEEE Press, 2015: 846–850.
- [16] Zhang Xuyao, Bengio Y, Liu Chenglin. Online and offline handwritten Chinese character recognition: A comprehensive study and new benchmark[J]. Pattern Recognition, 2017, 61: 348–360.
- [17] IOFFE S, SZEGEDY C. Batch Normalization: Accelerating Deep Network Training by Reducing Internal Covariate Shift (Version 3.0) [EB/OL]. (2015–03–02) [2019–12–20] <https://arxiv.org/pdf/1502.03167.pdf>
- [18] Xiao Xuefeng, Jin Lianwen, Yang Yafeng, et al. Building fast and compact convolutional neural networks for offline handwritten Chinese character recognition[J]. Pattern Recognition, 2017, 72(12): 72–81.
- [19] 林仁耀, 邓浩伟, 兰红. 卷积神经网络结合 SVM 的手写数字识别算法 [J]. 通信技术, 2019, 52(10): 2389–2394. LIN Ren-yao, DENG Hao-wei, LAN Hong. Handwritten Digits Recognition Algorithm based on Convolutional Neural Network and SVM [J]. Communications Technology, 2019, 52(10): 2389–2394.
- [20] 胡貌男, 邱康, 谢本亮. 基于改进卷积神经网络的图像分类方法 [J]. 通信技术, 2018, 51(11): 2594–2600. HU Mao-nan, QIU Kang, XIE Ben-liang. Image Classification Method based on Modified Convolutional Neural Network [J]. Communications Technology, 2018, 51(11): 2594–2600.
- [21] 王建仁, 马鑫, 段刚龙等. 边缘智能背景下的手写数字识别 [J]. 计算机应用, 2019, 39(12): 3548–3555. WANG Jian-Ren, MA Xin, DUAN Gang-long, et al. Handwritten Numeral Recognition Under Edge Intelligence Background [J]. Journal of Computer Applications, 2019, 39(12): 3548–3555.

#### 作者简介:



侯杰 (1996—), 女, 硕士研究生, 主要研究方向为计算机视觉、图像处理、机器学习;

倪建成 (1971—), 男, 博士, 教授, 主要研究方向为计算机视觉、机器学习、大数据技术与研究。